

Reliable and Trustworthy Artificial Intelligence

Assignment #2: DeepXplore: Automated Whitebox Testing of Deep Learning Systems

Dept. AI
2022840006
김도현

1. 적대적 공격과 신경망 테스트의 결합 가능성

Assignment #1에서 구현한 FGSM과 PGD는 gradient를 활용해 신경망을 오분류시키는 적대적 공격 기법이다. DeepXplore는 여러 모델 간의 예측 불일치를 gradient로 탐색하는 차등 테스트 프레임워크다. 두 접근법은 모두 gradient를 통해 신경망의 취약점을 드러낸다는 점에서 본질적으로 유사하며, 이를 결합하면 서로의 한계를 보완할 수 있다.

2. 시너지: 적대적 예제를 seed로 활용

가장 직접적인 결합 방식은 FGSM/PGD로 생성한 적대적 예제를 DeepXplore의 seed input으로 사용하는 것이다. 일반 테스트 이미지를 seed로 쓸 때보다 이미 모델의 decision boundary 근처에 위치한 적대적 예제를 seed로 사용하면, DeepXplore가 disagreement input을 더 적은 perturbation 단계로 찾을 수 있다. 실제로 본 실험에서도 perturbation 초기 단계부터 disagreement가 빠르게 발생했는데, 이는 두 모델의 decision boundary가 입력 공간에서 복잡하게 얽혀 있음을 보여준다. 적대적 예제는 이미 이 경계 근처에 있으므로 더욱 효율적인 탐색이 가능할 것이다.

3. Coverage-guided 공격

반대 방향의 결합도 가능하다. PGD의 목표를 "오분류 최대화"에서 "뉴런 커버리지 최대화"로 변경하거나, 두 목표를 동시에 최적화하는 방식이다. 이를 통해 기존 공격이 탐색하지 못했던 신경망의 다양한 실행 경로를 커버하면서 동시에 오분류를 유도할 수 있다. 본 실험에서 Model B의 커버리지(52.63%)가 Model A(31.93%)보다 높게 나타난 것은, 다양한 특징을 학습한 모델일수록 더 많은 뉴런이 활성화된다는 것을 보여준다. Coverage를 공격 목표에 포함시키면 모델의 더 깊은 취약점을 드러낼 수 있다.

4. 효율성

두 기법을 결합하면 버그 탐색 효율도 높아진다. DeepXplore 단독으로는 disagreement를 찾더라도 그 입력이 실제로 인간에게 자연스러운지 보장하기 어렵다. 반면 FGSM/PGD는 perturbation의 크기를 epsilon으로 엄격히 제한하므로, 적대적 공격으로 생성된 seed를 활용하면 더 자연스러운 disagreement input을 얻을 수 있다.

5. 한계

다만 결합이 항상 유익하지는 않다. 적대적 공격은 특정 모델에 대해 최적화되므로, 한 모델에 효과적인 적대적 예제가 다른 모델에는 큰 영향을 주지 않을 수 있다(transferability 문제). 또한 두 목표를 동시에 최적화할 경우 loss 간의 균형 조정이 어려워 오히려 두 기법 모두의

성능이 저하될 수 있다.

결론적으로, 적대적 공격과 신경망 테스트는 상호 보완적인 관계에 있으며, 적절히 결합하면 신경망의 신뢰성 검증을 더욱 효과적으로 수행할 수 있다.